马昕玥

maxinyue@hsc.pku.edu.cn | github.com/CnythiaMa

18009057142 | 预计博士毕业时间：2027年1月

25岁 | 女 | **高速进化的 AI 算法实践者**

教育经历

北京大学 本科 2017年09月 - 2021年06月

药学院 **药学** | 国家发展研究院 **经济学双学位**

北京大学 直博在读 2021年09月 - 2027年1月

药学院 分子与细胞药理系 神经药理学 | 导师：黄卓教授

技术技能

AI4Science / 生命科学大模型研究员，有完整的大模型数据构造–CPT 预训练–评测–推理部署经验。

- **编程语言：** Python · Bash · C++ · Git ·
- **深度学习：** PyTorch · **Megatron-LM** · **vLLM** · HuggingFace Transformers
- **大模型工程：** 持续预训练（CPT）· BPE 词表扩展 · MaaS API 调用
- **数据工程：** 大规模文本/生物序列清洗与构建 ·分布式数据库使用（OceanBase）
- **生命科学领域知识：** 神经科学；分子生物学；膜片钳电生理；代谢；癫痫；离子通道
- **语言：** 中文（母语）· 英文（CET-6：568 分）

LLM实习经历

算秩未来（九坤 IQuest） Life Science LLM 算法实习生 **2025.09 - 至今 6个月**

- **数据构造**：主导生命科学大模型 CPT 阶段的多类型训练数据搭建，覆盖单领域（核酸 / 蛋白 / SMILES 小分子序列）、跨领域（生命科学序列 + 科学文本）两类数据，总量级达 **1T token**；

  通过直接下载、网络爬虫、书目召回三条路径系统性获取多源异构语料：从 NCBI、UniProt、ChEMBL 等权威数据库下载核酸 / 蛋白 / 小分子 / 药物-靶标等数据；爬取 DrugBank、UpToDate、IntuitionLabs、IQVIA 等医药网站补充行业知识；从美国国会图书馆等数据源构建 ~1,600 万条书目索引，建立大规模书籍召回能力。在此基础上将生命科学序列封装入自定义序列标签（special token），并将单领域数据入库至 OceanBase 分布式数据库，支持跨领域数据构造——涵盖序列与功能描述拼接、文献文本融合、基于中心法则的核酸-蛋白对等多类型语料。

- **持续预训练（CPT）**：定制化改造 Qwen3-4B 基底模型，扩展科学专用词表, 领域专用token压缩率提升 **4-5 倍；**使用 **Megatron**框架cpt，完成生命科学序列数据注入【示例仓库】。

  采用 BPE 算法扩展科学领域专用词表，使模型能够对核酸 / 蛋白质 / 小分子序列进行专用分词；随后采用 **Megatron** / HF Transformers 框架，将生命科学序列数据注入模型完成持续预训练。

- **评测与推理**：进行生命科学Benchmark 全景调研【示例网站】，构建评测套件集成进内部系统，支持 MaaS API 与 **vLLM** 本地推理的混合框架。

  覆盖知识推理、实验能力、序列操作、分子设计等维度，跟踪主流模型 SOTA 作为基准线；涵盖前沿知识推理（HLE、FrontierScience）、科学预测（SciPredict、deep-principle-sde）、生物学实验能力（LAB-Bench）等；对每个数据集完成数据筛选与格式标准化，并复现官方评测水平，为模型迭代提供可信的量化反馈。

荣誉奖项

- **北京大学优秀毕业生(2021)；北京大学五四奖学金(2018)；北京大学三好学生(2018、2019、2024)；**
- 北京大学药学院"张礼和院士-浙江医药"奖学金；北京大学富力医学教育奖学金；北京大学药学院扬子江药业奖学金；北京大学药学院澳美制药奖学金；北京大学优秀团员； 北京大学医学部优秀团干部；

代表性论文

- Lai, S.#, Zhang, L.#, Tu, X.#, **Ma, X.#（共同一作）**, Song, Y., Cao, K., Li, M., Meng, J., Shi, Y., Wu, Q., Yang, C., Lan, Z., Lau, C. G., Shi, J., Ma, W., Li, S., Xue, Y. X., & Huang, Z. (2024). Termination of convulsion seizures by destabilizing and perturbing seizure memory engrams. **Science advances (IF=12.5) （将学习记忆研究范式外推至癫痫：将癫痫病视为一种异常记忆，从而使用干记忆的研究和治疗方法治疗疾病）**
- He, L., Yu, Z., Geng, Z., Huang, Z., Zhang, C., Dong, Y., Gao, Y., Wang, Y., Chen, Q., Sun, L., **Ma, X.,** Huang, B., Wang, X., & Zhao, Y. (2022). Structure, gating, and pharmacology of human CaV3.3 channel. **Nature communications. (IF=15.7)（与结构生物学领域合作，解析钙通道蛋白结构，负责测量钙蛋白电流）**

学术会议经历

- 第一届脑科学创新与转化高峰论坛，宁波 2024.04
  协助导师主办会议。
- 第14届欧洲神经科学协会联合会大会（FENS2024），奥地利维也纳 2024.06
  参会并做poster展示
- 第39届国际生理科学联合会大会(IUPS2022)，北京 2022.05；第五届离子通道与受体青年学者学术论坛，南京2021.04；第六届离子通道与受体青年学者学术论坛，武汉 2022.07
  参会

兴趣与其他

- **兴趣爱好：**舞蹈（学校舞团团龄5年，参加多次校级大型演出）、摄影（历年课题组毕业照拍摄者）、旅行（擅长做攻略、攀登过海拔4km+的川西高原）。
- **学生工作经历：**南山中学北京校友会会长（2018-2019）；北京大学药学院团委组织部部长（2019-2020）；双一流国际建设论坛暨北京论坛(2018)志愿者；联合国项目事务所第二届生命科学峰会(2018)志愿者； 国家药监局药品安全科普讲解大赛(2019) 主持人；北京大学药学院元旦晚会(2020) 主持人。