



教育经历

北京大学 本科

2017年09月 - 2021年06月

药学院 药学 | 国家发展研究院 经济学双学位

北京大学 直博在读

2021年09月 - 2027年06月

药学院 分子与细胞药理系 神经药理学 | 导师：黄卓教授

实习经历

腾讯TEG 数据科学 青云计划实习生

2026.04 – 2026.06

- **后训练数据自动化质检**：为了提升混元基模后训练数据的质量，构建基于 **LLM-as-Judge** 的自动化质检与筛选pipeline，覆盖长文理解、复杂指令遵循、自然语言理解等任务类型；通过对接人类标注专家、迭代裁判模型 prompt，将百级人工标注样本中沉淀的质检标准泛化至万级训练数据的**自动筛选**，有效降低数据污染，交付数据在下游评测中带来正向收益。

自动化Pipeline 采用「规则预筛 + LLM judge」的分层架构，串联：任务分类、Prompt 质量判断、多回答优选排序、Thinking 质量检查、Answer 验证等环节；通过构造原子化的 rubric criteria，从逻辑正确性、幻觉、语言一致性、冗余度、答案一致性等维度对数据进行筛选，并针对不同环节匹配规则引擎或不同能力的裁判模型，以平衡成本与精度。

算秩未来 (九坤 IQuest) Life Science LLM 算法实习生

2025.09 – 2026.04

- **数据构造**：为了提升通用模型的生命科学能力，主导构建生命科学领域的 **CPT** 与 **SFT** 训练数据，覆盖单领域（核酸 / 蛋白 / SMILES 小分子序列）、跨领域（生命科学序列 + 科学文本）两类数据，总量级达 **1T token**；

通过直接下载、网络爬虫、书目召回三条路径系统性获取多源异构语料：从Hugging face、NCBI、UniProt、ChEMBL 等权威数据库下载核酸 / 蛋白 / 小分子 / 药物-靶标等数据；爬取 DrugBank、UpToDate、IntuitionLabs、IQVIA 等医药网站补充行业知识；从美国国会图书馆等数据源构建 ~1,600 万条书目索引，建立大规模书籍召回能力。在此基础上将生命科学序列封装入自定义序列标签 (special token)，并将单领域数据入库至 OceanBase 分布式数据库，支持跨领域数据构造——涵盖序列与功能描述拼接、文献文本融合、基于中心法则的核酸-蛋白对等多类型语料。

- **持续预训练 (CPT)**：为了实现生命科学序列数据高效注入，定制化改造 Qwen3-4B 基底模型，扩展科学专用词表，领域专用 token 压缩率提升 **4-5 倍**。

采用 BPE 算法扩展科学领域专用词表，使模型能够对核酸 / 蛋白质 / 小分子序列进行专用分词；随后采用 **Megatron** / HF Transformers 框架，将生命科学序列数据注入模型完成持续预训练。

- **评测与推理**：为了评估模型在生命科学垂域的能力，进行生命科学Benchmark 全景调研【[示例采样](#)】，将分散的生命科学相关评测基准集成到统一框架【[Leaderboard网页](#)】。

覆盖知识推理、实验能力、序列操作、分子设计等维度，跟踪主流模型 SOTA 作为基准线；涵盖前沿知识推理 (HLE、FrontierScience)、科学预测 (SciPredict、deep-principle-sde)、生物学实验能力 (LAB-Bench) 等；对每个数据集完成数据筛选与格式标准化，并复现官方评测水平，支持 MaaS API 与 vLLM 本地推理的不同评测模式，为模型迭代提供可信的量化反馈。

技能

- **编程语言**：Python · R
- **深度学习**：PyTorch · **Megatron-LM** · **vLLM** · HuggingFace Transformers
- **大模型工程**：持续预训练 (CPT) · BPE 词表扩展 · MaaS API 调用 · Prompt Engineering
- **数据工程**：大规模文本/生物序列清洗与构建 · 分布式数据库使用 (OceanBase)
- **生命科学领域知识**：神经科学；生物信息学（基因组、代谢组学分析）；分子生物学；膜片钳电生理

荣誉奖项

北京大学优秀毕业生(2021)；北京大学五四奖学金(2018)；北京大学三好学生(2018、2019、2024)；

北京大学药学院“张礼和院士-浙江医药”奖学金；北京大学富力医学教育奖学金；北京大学药学院扬子江药业奖学金；北京大学药学院澳美制药奖学金；北京大学优秀团员；北京大学医学部优秀团干部；

代表性论文

- Lai, S.#, Zhang, L.#, Tu, X.#, **Ma, X.# (共同一作)**, Song, Y., Cao, K., Li, M., Meng, J., Shi, Y., Wu, Q., Yang, C., Lan, Z., Lau, C. G., Shi, J., Ma, W., Li, S., Xue, Y. X., & Huang, Z. (2024). [Termination of convulsion seizures by destabilizing and perturbing seizure memory engrams](#). *Science advances* (IF=12.5) (将学习记忆研究范式外推至癫痫：将癫痫病视为一种异常记忆，从而使用干记忆的研究和治疗方法治疗疾病)
- He, L., Yu, Z., Geng, Z., Huang, Z., Zhang, C., Dong, Y., Gao, Y., Wang, Y., Chen, Q., Sun, L., **Ma, X.**, Huang, B., Wang, X., & Zhao, Y. (2022). [Structure, gating, and pharmacology of human CaV3.3 channel](#). *Nature communications*. (IF=15.7) (与结构生物学领域合作，解析钙通道蛋白结构，测量钙蛋白电流)

学术会议经历

- 第一届脑科学创新与转化高峰论坛，宁波 2024.04
协助主办会议
- 第14届欧洲神经科学协会联合会大会（FENS2024），奥地利维也纳 2024.06
参会并做poster汇报
- 第39届国际生理科学联合会大会(IUPS2022)，北京 2022.05；第五届离子通道与受体青年学者学术论坛，南京2021.04；
第六届离子通道与受体青年学者学术论坛，武汉 2022.07
参会

兴趣与其他

- **兴趣爱好**：舞蹈（学校舞团团龄5年，参加多次校级大型演出）、摄影（历年课题组毕业照拍摄者）
- **学生工作经历**：南山中学北京校友会会长（2018-2019）；北京大学药学院团委组织部部长（2019-2020）；双一流国际建设论坛暨北京论坛(2018)志愿者；联合国项目事务所第二届生命科学峰会(2018)志愿者；国家药监局药品安全科普讲解大赛(2019) 主持人；北京大学药学院元旦晚会(2020) 主持人。